创新实践基地共享设备与物料管理智能体
项目说明书

项目名称：Managing-Agents-Chasing-Light

2026 年 3 月 27 日

目录

1 问题背景 **3**

2 需求分析 **3**

2.1 目标用户与角色 3

2.2 核心需求 3

2.3 非功能需求 4

3 智能体架构 **4**

3.1 总体架构 4

3.2 感知-推理-执行闭环 4

3.3 双引擎回答机制 4

4 技术方案 **5**

4.1 技术栈 5

4.2 数据模型设计 5

4.3 排程与推荐策略 5

4.4 LLM 接入方案（用户自带 API Key） 5

4.5 治理分析能力 6

5 创新点 **6**

6 应用场景 **6**

7 测试效果 **6**

7.1 测试范围 6

7.2 结果 7

8 应用成效与可行性结论 **7**

9 后续优化方向 **7**

1 问题背景

高校创新实践基地通常同时管理 3D 打印机、激光切割机、开发板、电子元器件、万用表等多种资源，典型痛点包括：

- 资源利用率不高：设备空闲与排队并存，预约效率低；
- 占用不均：热门设备被少数用户/项目长期占用，公平性差；
- 耗材浪费：超量领用、计划与实际偏差大；
- 工具丢失与损坏追溯困难：归还异常缺少结构化证据与后续任务闭环；
- 管理流程割裂：申请、审批、借还、盘点、预警分散在不同系统或人工台账中。

本项目围绕上述问题构建“共享资源管理智能体”，目标是实现开放管理、自主使用、可追溯治理与智能决策支持。

2 需求分析

2.1 目标用户与角色

- 学生：查询库存/空档，提交借用与领用申请，归还设备；
- 教师：审批申请，处理异常（报失/驳回/追责）；
- 管理员：资源与库存管理、全局分析、策略优化。

2.2 核心需求

需求类别	需求点	系统实现
目标导向	提升利用率、降低浪费与丢失、提升管理效率	提供排程推荐、异常治理建议、审批流与库存闭环
感知能力	感知用户输入与系统实时状态	接收自然语言、读取库存/审批/告警/流水/证据数据
推理规划	能进行时段推荐、风险分析、治理建议	规则工具推理 + LLM 语言组织；输出“结论 + 建议 + 理由”
执行能力	可执行业务动作	支持借用/领用申请、审批通过/驳回、补货、报失等可确认执行动作
多工具协同	业务工具与分析能力联动	调度器、审批服务、规则引擎、增强分析、证据流接口协同

实用可行性	可落地运行、可测试、可演示	FastAPI + SQLite + 前端工作台，完整 API 与回归测试

2.3 非功能需求

- 安全性：JWT 鉴权、角色权限隔离、会话 owner 绑定；
- 可靠性：工具执行前确认机制、失败回退规则引擎；
- 可维护性：模块化路由/服务/数据模型，接口文档清晰；
- 可验证性：端到端测试覆盖关键流程。

3 智能体架构

3.1 总体架构

系统采用“前端工作台 + 后端智能体服务 + 业务工具层 + 数据层”的分层架构：

- 表现层：`/dashboard-main` 统一工作台（资源、审批、库存、智能体对话）；
- 智能体层：`/agent/chat`、`/enhanced-agent/ask`；
- 工具层：排程、审批、交易、规则引擎、增强分析、证据管理；
- 数据层：SQLite（资源、实例、流水、审批、告警、会话消息等）。

3.2 感知-推理-执行闭环

1. 感知：解析用户自然语言（设备、时间、时长、项目等）与实时业务数据；
2. 推理：进行意图识别、时段打分、冲突检查、治理建议生成；
3. 执行：对可变更动作进入“待确认”状态，用户确认后再写入业务流水；
4. 反馈：返回结果、解释理由与下一步建议，并记录会话上下文。

3.3 双引擎回答机制

- 确定性业务引擎：保证库存/审批等关键事实不臆造；
- 大模型润色引擎：在事实不变前提下提升表达自然度与可执行性；
- 失败回退：模型不可用时自动回退规则引擎，保证服务连续。

4 技术方案

4.1 技术栈

- 后端：FastAPI + SQLAlchemy；
- 数据库：SQLite（可扩展至 MySQL/PostgreSQL）；
- 前端：原生 HTML/CSS/JS 工作台；
- 模型接入：OpenAI 兼容 `/chat/completions`；
- 测试：Pytest。

4.2 数据模型设计

核心实体包括：

- **Resource**（资源类型层）：设备/耗材总量、可用量、阈值等；
- **ResourceItem**（资源实例层）：资产编号、状态、借用人、维护记录；
- **Transaction**（业务流水）：borrow/consume/replenish/lost/adjust；
- **ApprovalTask**（审批任务）：待审/通过/驳回；
- **Alert**（预警）、**FollowUpTask**（后续任务）；
- **ChatSession/ChatMessage**（会话与消息）。

4.3 排程与推荐策略

排程模块综合冲突、时间偏好、历史占用等因素打分，向用户返回“结论 + 建议 + 时段明细”。示例指标：

$$U_r = 1 - \frac{A_r}{T_r}$$

其中 U_r 为资源占用率，A_r 为可用量，T_r 为总量。

4.4 LLM 接入方案（用户自带 API Key）

为满足“智能体需可调用大模型 API”与现场演示便利性，系统支持在前端输入用户自己的：

- `base_url`、`model`、`api_key`、`timeout`；
- 按请求传入 `llm_options`，后端优先使用请求参数；
- 不写入数据库，模型不可达时自动回退规则引擎。

4.5 治理分析能力

系统提供公平性与异常治理指标，包括：

- 超时未归还、黄金时段占用集中度；
- 项目预计用量 vs 实际用量偏差；
- 用户/项目/资源异常评分；
- 补货建议与风险优先级。

5 创新点

1. **“确定性业务工具 + LLM” 双引擎架构**：兼顾事实可靠性与交互自然性；
2. **可执行智能体**：不仅问答，还可发起申请、审批、补货、报失等动作；
3. **确认执行机制**：关键动作先确认后落库，降低误操作风险；
4. **资源双层建模**：类型库存 + 实例资产，支持追溯与精细管理；
5. **用户自定义模型接入**：支持用户现场输入 API Key 体验推理能力；
6. **治理导向输出**：直接面向“利用率不高、占用不均、浪费、丢失”给出可执行建议。

6 应用场景

场景	系统价值
创新基地日常管理	统一入口处理申请、审批、借还、补货、报失与预警
课程实验高峰期调度	快速给出空档与推荐时段，缓解排队与冲突
耗材预算与成本控制	识别高量领用与偏差项目，辅助预算复盘
资产盘点与追责	归还异常、报失、维护任务闭环，提升可追溯性
答辩与展示	可在前端直接接入用户模型，展示“可推理可执行”的智能体能力

7 测试效果

7.1 测试范围

- 鉴权与会话隔离；

- 借用申请-审批-库存变更闭环；
- 归还异常（损坏、部分丢失）与后续任务生成；
- 智能体排程回答质量（结论、建议、理由）；
- 请求级 LLM 配置（含增强路由）；
- 分析接口与数据结构正确性。

7.2 结果

本地回归测试结果：**29 passed**。关键现象：

- “后天上午/下午”时间语义解析正确；
- 排程回复由“生硬列表”优化为“先回答是否有空档，再给建议与理由”；
- 用户输入自定义 API Key 后可触发模型路径，失败时平滑回退。

8 应用成效与可行性结论

项目已实现“目标导向、感知-推理-执行闭环、工具协同、可落地部署”的智能体系统形态，能够直接服务创新实践基地共享资源管理。系统既能提供稳定业务自动化，也支持用户按需接入大模型增强推理表现，具备较高的实用性、创新性与技术可行性。

9 后续优化方向

- 引入更细粒度的时段容量模型（按设备实例并发）；
- 增强多智能体协作（调度体、审批体、风控体分工）；
- 接入消息通知（飞书/企业微信）实现异常闭环提醒；
- 增加长期效果评估看板（利用率提升、浪费率下降、丢失率下降）。